

Propuesta: primeros 90 días en Observabilidad y Automatización

Para: Directora de Operaciones de TI · **Caso:** PortalPagos (Andina Financiera) · **Base:** hallazgos de los Retos 1 a 4

Punto de partida. El 18/09 el portal falló durante 1 h 44 min en un día de cierre de plazo. Nos enteramos por los clientes, el NOC reportó "100 %" y el caso se cerró sin causa. Los datos muestran que la falla **se podía ver venir 46 horas antes** y que **hoy siguen activos dos riesgos**: el disco C: se llena en días y la caída se repetirá en el próximo día de muchos pagos. Este plan busca tres cosas: **contener esos riesgos, enterarnos antes que el cliente y dejar de depender de reinicios manuales.**

1. Iniciativas, en orden de prioridad

#	Iniciativa	Qué entrega	Impacto	Esfuerzo	Riesgo	Cuándo
1	Contener los riesgos activos	Liberar disco conservando los volcados de memoria (evidencia). Bajar el log de Debug a Information. Reciclaje del pool por memoria (1 GB) como mitigación temporal. Reemplazar el .bat por el script del Reto 2 (sin contraseña, sin iisreset)	Muy alto: evita la próxima caída	Bajo: días	Bajo: cambios reversibles y probados	Semanas 1-2
2	Monitorear lo que vive el cliente	Recolección de logs, eventos y métricas en Log Analytics. Una prueba sintética que inicia sesión y consulta saldos , en lugar del /health actual. Indicador de disponibilidad por operación (SLO 99,9 %). Seis alertas accionables: errores 5xx, latencia p95, pool detenido, memoria del proceso, disco con pronóstico y dumps nuevos. Tableros para la Dirección y el NOC	Muy alto: de 0 % a 80 % de incidentes detectados antes que el cliente	Medio	Bajo: solo observa, no cambia el portal	Semanas 2-6
3	Auto-remediación con salvaguardas	Si el pool se detiene: capturar diagnóstico, iniciarlo y verificar. Máximo 2 intentos por hora. No actúa durante despliegues ni si el problema es de disco. Escala a una persona si falla. Todo queda registrado. Empieza en modo sugerencia 2 semanas antes de actuar sola	Alto: el tiempo de recuperación baja de 101 min a menos de 15	Medio	Medio: un reinicio automático puede esconder causas; se mitiga con límites, diagnóstico previo y revisión semanal	Semanas 5-9
4	Verificación después de cada despliegue	Comparación automática de memoria, latencia y errores 24 h antes y después de cada cambio, con el despliegue marcado en el tablero. La salida a producción requiere esa verificación en verde. Post-mortem sin culpables para todo incidente Sev1	Alto: la causa raíz fue un despliegue que nadie vigiló	Medio: es sobre todo acuerdo de proceso	Bajo	Semanas 6-12
5	Triage asistido por IA en el canal del NOC	Cada alerta llega con un resumen, hipótesis con evidencia citada y un runbook sugerido del catálogo (Reto 4). Sugiere; la persona decide	Medio: ahorra los primeros 15-20 min de cada incidente	Bajo: ya está construido	Medio: el modelo puede equivocarse; se mitiga con validación de citas y modo degradado	Semanas 8-12

Por qué en este orden. La 1 elimina riesgos con fecha. La 2 es la base de todo lo demás: sin datos confiables no se puede automatizar con seguridad. La 3 solo se activa cuando la 2 lleva semanas midiendo bien. La 4 ataca la causa de fondo (cambios sin verificar). La 5 es la de menor impacto: solo aporta si las alertas ya son buenas.

2. Cómo mediríamos el éxito

Las líneas base salen de los datos de la semana del 14 al 20 de septiembre.

Indicador	Hoy (línea base)	Meta a 90 días	Cómo se mide
Tiempo de detección (MTTD): del inicio del impacto a que Operaciones lo reconoce	79 min (errores desde las 13:23; ticket crítico a las 14:42)	< 5 min	Hora de inicio del impacto en los logs contra la hora de la alerta. Con la alerta de 5xx el incidente se habría detectado a las 13:25
Tiempo de recuperación (MTTR): del inicio del impacto a la recuperación	101 min (13:23 a 15:04)	< 15 min en fallas del pool	Inicio del impacto contra la vuelta a menos de 1 % de errores
Incidentes detectados antes que el usuario	0 % (0 de 2: la lentitud del 17/09 y la caída del 18/09 llegaron por tickets)	≥ 80 %	Hora de la alerta contra hora del primer ticket, revisado en cada post-mortem
Disponibilidad real (operaciones de clientes sin error)	98,46 % en la semana; el NOC reportó 100 %	≥ 99,9 % al mes (máximo 43 min de afectación)	Consulta KQL sobre los logs de IIS y HTTP.sys, visible en el tablero de la Dirección
Horas de trabajo manual (reinicios, revisiones, limpieza y diagnóstico de primer nivel)	Por medir: el kit no lo registra. Se medirá las semanas 1 y 2	-50 %	Registro de tiempo del NOC y tickets cerrados por automatización
Despliegues con verificación posterior	0 %	100 %	Despliegues con su comparación antes y después en el tablero

Indicador	Hoy (línea base)	Meta a 90 días	Cómo se mide
Alertas accionables (que requirieron hacer algo)	Sin alertas de usuario	≥ 80 %	Revisión mensual de alertas. Las que no sirven se ajustan o se eliminan

3. Qué necesito que me destrabe

1. **Un cambio de emergencia esta semana** para la iniciativa 1: liberar disco, bajar el log y configurar el reciclaje por memoria. Al ritmo actual, **el disco C: se llena en días**.
2. **Compromiso del equipo de desarrollo** para corregir la caché de sesiones de pago (v2.3.1), y **un dueño del portal** que apruebe el SLO de 99,9 % con el negocio.
3. **Accesos:** permiso para instalar el agente de Azure Monitor en WEB-PAGOS-01; un grupo de recursos con presupuesto para Log Analytics (estimado: decenas de dólares al mes, que se confirmarán con los primeros datos); y una **cuenta gMSA** para el script de mantenimiento (equipo de Directorio Activo).
4. **El calendario de vencimientos de pago**, para revisar capacidad antes de cada día pico.
5. **Una guardia definida y una ruta de escalamiento:** a quién llama la automatización cuando no debe o no puede actuar.
6. **Aval de Seguridad para usar un modelo de IA** con logs: idealmente Azure OpenAI dentro del tenant, revisando antes si las IPs de clientes deben enmascarse.

4. Qué no haría, y por qué

No haría	Por qué
Comprar o cambiar de plataforma de monitoreo en estos 90 días	El problema no fue la herramienta sino qué se medía . Azure Monitor ya cubre lo necesario; una migración consumiría el trimestre sin reducir el riesgo
Automatizar reinicios "a ciegas" o mantener el iisreset nocturno	Un reinicio sin límites oculta la causa : el iisreset diario escondió la fuga hasta el día de más pagos. Solo con diagnóstico previo, límite de intentos y escalamiento
Dejar que la IA ejecute acciones	En un portal de pagos regulado, una sugerencia equivocada debe costar un minuto de revisión, no una caída. La IA resume y sugiere; la persona decide
Crear decenas de alertas desde el primer día	La fatiga de alertas lleva a ignorarlas. Empezaría con 6 ligadas al impacto en el cliente y agregaría solo las que demuestren ser útiles
Tratar las alertas DCOM 10016 como causa (ticket T-10261)	Los datos muestran que aparecen igual toda la semana. Perseguirlas desvía tiempo de los riesgos reales
Rediseñar o migrar el portal en este periodo	Es necesario a futuro, pero es un proyecto de otra escala. Primero hay que poder ver el sistema para decidir con datos qué cambiar